

MemoryBase：面向组织与团队的 AI-native 可追溯长期记忆数据库系统设计与实现

课程：CS3321 数据库技术
小组成员：林纪帆、杜卓轩、李昭成、王星睿

摘要

AI Agent 和团队协作系统会持续产生会议纪要、讨论记录、项目文档、决策、偏好等多种多样的日志文档。这些长期知识通常只保存在聊天历史或 Markdown 文件中，这导致后续很难进行结构化查询、来源追溯、权限过滤、版本审计以及选择性遗忘。面对以上困境，MemoryBase 尝试以 PostgreSQL 为事实源，把长期记忆建模为一套可查询、可追溯、可治理、可被人和 Agent 共同使用的数据库系统。

具体来说，我们的系统采用“文件—数据库双态”架构：文件侧保留 Markdown / txt source 和可导出的 Markdown Wiki，以服务人类阅读、迁移和审阅；数据库侧则使用 `source_document`、`source_chunk`、`memory_item`、`memory_evidence`、`memory_revision`、`audit_log`、`access_policy`、`wiki_page` 等关系表管理记忆生命周期，以针对具体功能。系统已实现 source 导入、chunk 切分、memory 创建与候选抽取、evidence 追溯、revision/audit 自动记录、全文检索、agent-aware visibility、冲突/遗忘治理、Wiki 投影、Graph Explorer、CLI/Agent Runtime、hybrid recall fallback 和 evaluation framework 等多种功能。

我们的项目展示了完整的概念结构设计、E-R 图、关系模式转换、范式分析、物理结构设计、索引、视图、触发器、完整性约束、SQL 查询、EXPLAIN 证据，并提供带注释源程序。LongMemEval 500-case 工程评测显示当前系统在 semantic judge 下通过率为 58.4%，说明我们的系统具备长期记忆任务验证能力；当然，我们的系统也仍有值得提升之处：multi-session reasoning 和 preference following 仍是后续优化重点。

关键词：长期记忆数据库；PostgreSQL；Provenance；Governance；Agent Visibility；Audit Log；Hybrid Recall；Graph Explorer；Evaluation

1. 项目概述

1.1 项目定位

MemoryBase 是一个面向组织与团队的 AI-native 可追溯长期记忆数据库系统。它不是从零实现 DBMS，也不是普通 RAG 问答应用，而是数据库应用系统：以成熟关系数据库作为底座，专注于设计和实现长期记忆的关系模型、完整性约束、检索路径、权限治理、审计和人机协作入口。

系统的一句话介绍是：

把人类可读的 Markdown、会议纪要和项目文档，编译为人和 Agent 都能访问、可追溯、可权限控制、可审计、可版本化的长期记忆数据库。

MemoryBase 解决的核心问题包括：

问题	普通文件 / 聊天记录的局限	MemoryBase 的处理方式
信息分散	文档、会议纪要、聊天记录散落各处	<code>source_document</code> / <code>source_chunk</code> 统一导入和切分
结论难追溯	记忆不知道来自哪段原文	<code>memory_evidence</code> 绑定 <code>source chunk</code> 和行号
修改不可审计	旧版本和操作者不可回放	<code>memory_revision</code> + <code>audit_log</code>
权限不可靠	只靠 prompt 或 UI 约定	<code>access_policy</code> + <code>v_agent_visible_memory</code>
冲突和遗忘难治理	删除或覆盖后缺少审批链	<code>conflict_record</code> + <code>forget_request</code>
Agent 难使用	文件适合人读，不适合结构化上下文	Recall / Search / Context Pack / CLI
人类难审阅	数据库记录不适合直接阅读	<code>wiki_page</code> / <code>wiki_page_revision</code> 导出 Markdown

1.2 核心链路

系统核心数据链路为：

```
SourceDocument
-> SourceChunk
-> MemoryItem
-> MemoryEvidence
-> MemoryRevision / AuditLog
-> RecallLog / AccessPolicy
-> WikiPage / WikiPageRevision
```

这条链路体现了项目的主线：长期记忆不是孤立文本，而是带来源、版本、权限、审计和表达投影的数据库对象。

1.3 已实现功能

核心能力（不依赖外部 LLM，也不依赖向量数据库）：

- 导入 Markdown / txt source;
- 自动切分 source chunk;
- 创建、编辑、归档 memory;
- 绑定 memory evidence;
- 记录 memory revision 和 audit log;
- 关键词 / 全文检索;
- Markdown Wiki 导出;
- 前端基础页面和 SQL 演示数据。

扩展能力包括：

- agent-aware visibility 和 policy 过滤;
- ConflictRecord 冲突治理;
- ForgetRequest 遗忘/归档审批;
- rule-based + optional LLM candidate memory extraction;
- local hashing embedding cache 与 hybrid recall fallback;
- Graph Explorer (PostgreSQL preview + 可选 Neo4j sync) ;
- CLI / Agent Runtime sessions、observe、remember、search、recall;
- evaluation framework (LoCoMo / LongMemEval / MemoryAgentBench 等 adapter) 。

1.4 报告材料入口

如果想对本项目有更全面了解，可以参考以下报告：

材料	用途
docs/00-project-overview.md	项目总览和核心链路
docs/gap2-research-landscape.md	研究现状分析
docs/01-requirements.md	需求分析
docs/02-data-flow.md	数据流图
docs/03-data-dictionary.md	数据字典
docs/04-er-design.md / docs/final-assets/diagrams/	ER 和流程图
docs/05-logical-design.md / docs/normalization.md	逻辑结构和范式分析
docs/06-physical-design.md / docs/index-rationale.md / docs/explain-analyze.md	物理设计、索引和 EXPLAIN
docs/07-system-architecture.md / docs/08-api-design.md / docs/09-module-ipo.md	系统架构、API 和模块 IPO
docs/10-test-plan.md / docs/final-assets/screenshots/	测试与截图证据
docs/gap3-innovation-analysis.md	创新点展开
docs/gap6-contribution-ledger.md	小组分工和个人贡献
docs/gap8-source-sql-appendix-map.md	带注释 SQL / 高级语言源程序附录

2. 研究现状分析

2.1 传统 RAG 与向量检索

Retrieval-Augmented Generation (RAG) 通过 “文档切分、embedding、向量召回、上下文拼接” 增强 LLM 对外部知识的访问能力。它的优势是实现快、语义召回强、生态成熟，LangChain、LlamaIndex 等框架也降低了工程门槛。

但普通 RAG 更关注 chunk 检索和回答效果，较少把 chunk、memory、evidence、revision、audit、policy、wiki projection 建模为有完整生命周期的业务对象。它能返回相关片段，却不一定能回答：这条 memory 来自哪份 source？谁修改过？Agent 是否有权限看？source 被遗忘后是否还会被召回？一次 hybrid recall 为什么降级到 keyword？

MemoryBase 保留 RAG 的检索思想，但以 PostgreSQL 关系模型为核心：source、chunk、memory、evidence、recall log 和 audit 都是可查询对象；而 embedding cache 只是可选增强，不是唯一事实源。

2.2 Agent 长期记忆系统

MemGPT / Letta、Mem0、MemoryBank、LongMem、Generative Agents 等系统说明长期记忆已经成为 Agent 基础设施。它们强调 core memory、archival memory、动态抽取、合并、检索和跨会话状态维护。

这些工作证明 Agent 确实需要长期记忆，但从数据库课程和组织治理角度看，它们通常更关注 “模型是否记得并用上”，而不是 schema、外键、范式、触发器、审计链、权限视图和 SQL 可验证性。MemoryBase 的差异化是把 Agent 记忆问题落到数据库系统：Agent 可以用 CLI/API 做 recall、search、observe、remember，但每次写入和召回都落入可约束、可审计、可复现的数据库结构。

2.3 产品化记忆和企业知识库

ChatGPT Memory 代表消费者产品中的记忆能力，用户可以管理 saved memories 和 reference chat history；Confluence AI / Atlassian RoVo 与 Notion AI Enterprise Search 代表企业知识管理中的 AI search、chat、agents 和 workspace automation；Obsidian / Logseq 则代表本地文件型知识库。

这些产品既说明长期记忆和知识管理是实际需求，也显示一大问题：这些产品大多不开放底层关系 schema、触发器、SQL EXPLAIN、审计表和多租户权限策略等内容。MemoryBase 吸收了它们在人类可读、wiki、搜索和引用方面的优点，同时也满足数据库课程所要求的可建模、可约束、可审计和可复现。

2.4 长期记忆评测与 GraphRAG

LoCoMo、LongMemEval、MemoryAgentBench 等 benchmark 从多 session、长期对话、时间推理、信息更新、选择性遗忘等角度评估 memory agent 能力。GraphRAG 则强调在 chunk / vector 之外构建实体关系图和社区摘要，提升跨文档关系理解。

MemoryBase 已接入 evaluation framework，并实现 Graph Explorer。graph 用于 provenance 和 governance 可视化，PostgreSQL 是权威事实源。当前 LongMemEval 结果显示系统已有长期记忆工程验证路径。

2.5 现有方案的共同不足

综合来看，现有路线存在四类不足：

- 1. 可追溯性不足：能召回结果，但不能稳定说明 memory 与 source、chunk、revision、approval 的关系。
- 2. 关系建模不足：向量库擅长相似度，但不擅长表达 evidence、policy、audit、forget request 等关系。
- 3. 治理能力不足：组织场景需要权限、冲突、遗忘、归档、审计和多角色访问。
- 4. 课程可验证性不足：黑盒 AI 工具难以展示 E-R 图、关系模式、范式、索引、视图、触发器和 EXPLAIN。

MemoryBase 的切入点正是把长期记忆作为数据库应用系统来建模。

3. 需求分析

3.1 用户角色

角色	使用目标	主要操作	权限边界
普通用户	搜索项目记忆、查看 source、阅读 Wiki	搜索、查看、导出	默认只看 public/project 范围
小组成员	维护课程项目记忆	导入 source、创建/编辑 memory、处理 conflict	不能绕过 workspace 和 policy
Agent	基于权限读取 context pack，写入观察和记忆	recall、search、observe、remember	必须经过 agent visibility 过滤
管理员	管理权限、审计、冲突和遗忘	policy、audit、conflict、forget request	操作写入 audit
访客 / 只读用户	查看公开 Wiki 或演示结果	浏览和搜索公开内容	不能编辑或查看审计详情

3.2 功能需求

模块	功能	优先级
Workspace 基础配置	初始化 workspace、维护成员和边界	P0
Source 导入	导入 Markdown / txt，切分 chunk	P0
Memory 管理	创建、编辑、删除 memory	P0
Evidence 追溯	memory 绑定 source chunk	P0
Revision / Audit	修改自动记录版本和审计	P0
Recall 检索	keyword / FTS / hybrid recall	P0/P1
Markdown Wiki	导出 WikiPage 和版本	P0
AccessPolicy	Agent 权限过滤	P1
ConflictRecord	冲突记忆治理	P1
ForgetRequest	遗忘与归档审批	P1
Graph Explorer	展示 source/memory/evidence/wiki/governance 关系	P1
Agent Runtime / CLI	sessions、observe、remember、search、recall	P1
Evaluation	长期记忆评测适配器、指标和报告	P1
QA	基于 recall context 的可选 LLM answer	P2

3.3 非功能需求

类别	要求	实现方式
数据完整性	不允许孤立 evidence、revision	主键、外键、UNIQUE、CHECK
可追溯性	每条 memory 可追到 source chunk	memory_evidence、v_memory_with_source
权限控制	Agent 只能看授权范围	access_policy、v_agent_visible_memory
可审计性	关键操作可回放	audit_log、trigger、before/after JSON
可降级性	没有 LLM / embedding 也能演示	rule-based extraction、keyword fallback
可演示性	5-8 分钟讲清核心闭环	seed + governance fixture + screenshot assets
性能需求	课程规模下秒级查询	B+ tree、GIN、BRIN、covering index

4. 数据流设计

4.1 0 层数据流图

外部实体包括普通用户/小组成员、Agent、管理员、Markdown/会议纪要文件和 Markdown Wiki 文件系统。核心内容是 MemoryBase 长期记忆数据库系统。主要数据存储包括 Source Store、Memory Store、Governance Store、Wiki Store 和 Audit Store。

```
User / Agent / Admin / Source files
  -> MemoryBase
  -> Source Store / Memory Store / Governance Store / Wiki Store / Audit Store
  -> Markdown Wiki / Context Pack / UI / SQL evidence
```

4.2 1 层数据流

```
Markdown / txt 文件
  -> Source Ingest
  -> SourceDocument / SourceChunk
  -> Memory Extract / Manual Edit
  -> MemoryItem / MemoryEvidence
  -> Semantic Organization
  -> Entity / MemoryScene
  -> Recall Search
  -> Context Pack
  -> Wiki Export
  -> WikiPage / WikiPageRevision

关键操作
  -> Governance
  -> AuditLog / MemoryRevision / RecallLog / AccessPolicy
```

4.3 关键 2 层流程

Source 导入流程：

用户上传文件

- > 校验文件类型
- > 计算 checksum
- > 保存 SourceDocument
- > 按行数 / token 切分
- > 保存 SourceChunk
- > 通过 imported_at / imported_by_user_id 保留导入元数据

Recall 检索流程:

用户 / Agent 输入 query

- > 解析 query 和过滤条件
- > 应用 public/project 或 v_agent_visible_memory 过滤
- > 查询 SourceChunk FTS / trigram
- > 查询 MemoryItem 文本匹配
- > 可选查询 MemoryEmbedding / SourceChunkEmbedding
- > Join MemoryEvidence / SourceChunk / SourceDocument
- > 返回 memory + evidence + source
- > 写入 RecallLog

Wiki 导出流程:

选择 scene / memory / workspace

- > 查询 MemoryItem
- > 查询 MemoryEvidence
- > 查询 SourceChunk
- > 生成 Markdown frontmatter
- > 写入 WikiPage
- > 写入 WikiPageRevision
- > 导出 data/markdown_wiki/

5. 数据字典

5.1 核心数据项

数据项	含义	类型	约束示例
user_id	用户编号	UUID	PK
agent_id	Agent 编号	UUID	PK
workspace_id	工作区编号	UUID	PK / FK
doc_id	源文档编号	UUID	PK
chunk_id	文档块编号	UUID	PK
memory_id	记忆项编号	UUID	PK
evidence_id	证据编号	UUID	PK
revision_no	版本号	INT	与 memory/page 组成复合 PK
audit_id	审计日志编号	UUID	PK
access_level	访问范围	VARCHAR	public/project/team/private
memory_type	记忆类型	VARCHAR	episodic/semantic/fact/profile/procedural/decision/preference/task/risk/constraint/policy/summary
status	记忆状态	VARCHAR	candidate/active/archived/forgotten/superseded/rejected/conflicted

5.2 主要数据结构

数据结构	组成	说明
SourceDocument	doc_id、workspace_id、doc_type、title、raw_text、checksum、status、imported_at	原始文档
SourceChunk	chunk_id、doc_id、chunk_no、chunk_text、line range、search_vector	文档切块
MemoryItem	memory_id、workspace_id、memory_type、canonical_text、status、access_level、valid_from/valid_to	长期记忆核心
MemoryEvidence	evidence_id、memory_id、chunk_id、role、weight、note	记忆来源证据
MemoryRevision	memory_id、revision_no、text、summary、reason、editor	记忆版本历史
AuditLog	actor、action、target、before_json、after_json、created_at	操作审计
AccessPolicy	principal、resource、effect、scope	权限策略
WikiPage / WikiPageRevision	page metadata + markdown body	人类可读投影
MemoryEmbedding / SourceChunkEmbedding	provider、model、dimension、embedding_json、hash	可选向量缓存


完整数据字典见 docs/03-data-dictionary.md。

6. 概念结构设计与 E-R 图

6.1 概念分层

层次	主要实体	作用
源文档层	SourceDocument、SourceChunk、AgentSession、Message	保存原始输入
记忆层	MemoryItem、MemoryRevision、MemoryScene、MemoryEmbedding	保存长期记忆、版本和可选向量
证据层	MemoryEvidence、Entity、MemoryEntity	绑定记忆与来源，支持语义组织
表达层	WikiPage、WikiPageRevision、TimelineEntry	生成 Wiki 和时间线
治理层	AccessPolicy、RecallLog、ConflictRecord、ForgetRequest、AuditLog	权限、审计、冲突、遗忘

6.2 核心 E-R 图



完整 25 实体 ER 图见 docs/final-assets/diagrams/02-er-full.svg。核心关系包括：

联系	类型	转换方式
Workspace - SourceDocument	1:N	source_document.workspace_id
SourceDocument - SourceChunk	1:N	source_chunk.doc_id
SourceChunk - MemoryItem	M:N	memory_evidence
MemoryItem - MemoryRevision	1:N	memory_revision.memory_id
MemoryItem - Entity	M:N	memory_entity
MemoryScene - MemoryItem	M:N	memory_scene_cell
WikiPage - WikiPageRevision	1:N	wiki_page_revision
Workspace - AccessPolicy / AuditLog / RecallLog	1:N	workspace-scoped governance tables

6.3 设计说明

E-R 设计围绕以下生命周期组织：

```
ingest -> extract -> evidence -> revise -> retrieve -> govern -> project -> forget
```

其中 MemoryEvidence 是最关键的 M:N 关联：一条 memory 可以由多个 source chunk 支撑，一个 source chunk 也可以支撑多个 memory。它让系统从“文本检索”升级为“证据链建模”。

7. 逻辑结构设计 with 范式分析

7.1 关系模式

主要关系模式包括：

```
UserAccount(user_id PK, username UNIQUE, display_name, email UNIQUE, role_hint, created_at, updated_at)

Workspace(workspace_id PK, slug UNIQUE, name, description, scope_type, owner_user_id FK, created_at, updated_at)

Agent(agent_id PK, workspace_id FK, name, agent_type, status, owner_user_id FK, created_at)

SourceDocument(doc_id PK, workspace_id FK, session_id FK, doc_type, title, source_path, raw_text, checksum,
status, forgotten_at, imported_by_user_id FK, imported_at)

SourceChunk(chunk_id PK, doc_id FK, chunk_no, chunk_text, start_line, end_line, token_count, search_text_zh,
search_vector, UNIQUE(doc_id, chunk_no))

MemoryItem(memory_id PK, workspace_id FK, created_from_doc_id FK, memory_type, canonical_text, summary,
search_text_zh, search_vector, confidence, importance, status, access_level, owner_user_id FK, owner_agent_id
FK, valid_from, valid_to, superseded_by_memory_id FK, current_revision_no, created_at, updated_at)

MemoryEvidence(evidence_id PK, memory_id FK, chunk_id FK, evidence_role, weight, note, created_at,
UNIQUE(memory_id, chunk_id, evidence_role))

MemoryRevision(memory_id FK, revision_no, revision_text, revision_summary, revision_reason, editor_type,
editor_id, created_at, PK(memory_id, revision_no))

WikiPage(page_id PK, workspace_id FK, page_slug, page_type, title, current_revision_no, generated_from_scene_id
FK, generated_from_memory_id FK, needs_rebuild, status, forgotten_at, created_at, updated_at)

WikiPageRevision(page_id FK, revision_no, frontmatter_json, body_markdown, generated_by, created_at, PK(page_id,
revision_no))

AccessPolicy(policy_id PK, workspace_id FK, principal_type, principal_id, resource_type, resource_scope, effect,
predicate_json, created_at)

ConflictRecord(conflict_id PK, workspace_id FK, left_memory_id FK, right_memory_id FK, conflict_type, status,
resolution_note, resolved_by_actor_type, resolved_by_actor_id, resolved_at, created_at, updated_at)

ForgetRequest(request_id PK, workspace_id FK, target_type, target_id, requester_user_id FK, reviewed_by_user_id
FK, reason, status, requested_at, resolved_at)

AuditLog(audit_id PK, workspace_id FK, actor_type, actor_id, action_type, target_type, target_id, before_json,
after_json, created_at)
```

完整关系模式见 `docs/05-logical-design.md`。

7.2 E-R 到关系模型转换

1:N 关系通过在 N 端保存外键实现，例如 `source_document.workspace_id`、`source_chunk.doc_id`、`memory_revision.memory_id`。M:N 关系通过中间表实现，例如 `memory_evidence`、`memory_entity`、`memory_scene_cell`。版本化实体采用复合主键，例如 `memory_revision(memory_id, revision_no)` 和 `wiki_page_revision(page_id, revision_no)`。

7.3 范式分析

核心业务表以 3NF / BCNF 为主：

- 每张表有明确主键或复合主键；
- 非主属性直接依赖候选键；

- M:N 关系拆分为关联表；
- 版本内容从主表拆到 revision 表；
- 权限、审计、冲突、遗忘独立成治理表。

少数受控反规范化是有意设计：

字段	所在表	原因	一致性维护
search_vector	memory_item / source_chunk	支撑 GIN 全文检索	GENERATED column
current_revision_no	memory_item / wiki_page	快速读取当前版本	trigger
needs_rebuild	wiki_page	Wiki dirty bit	trigger
workspace_id	memory_entity / memory_scene_cell	支撑复合 FK 保证同租户	FK constraint
embedding_json	embedding tables	缓存模型输出向量	provider/model/hash 去重

完整函数依赖和范式判定见 docs/normalization.md。

8. 物理结构设计

8.1 数据库选择

主数据库采用 PostgreSQL。早期曾考虑 SQLite + FTS5 作为本地备选，但当前仓库脚本、测试和演示均以 PostgreSQL 为准，SQLite 不作为已交付能力。

选择 PostgreSQL 的原因：

- 支持复杂外键、CHECK、UNIQUE 和复合 FK；
- 支持 JSONB、GIN、BRIN、covering index、partial index；
- 支持 PL/pgSQL trigger；
- 适合展示数据库课程中的视图、索引、触发器和 EXPLAIN；
- 能承载多 workspace、多 user、多 agent 的组织级数据模型。

8.2 存储路径

project-root/	
database/	SQL schema, indexes, views, triggers, seed
backend/app/	FastAPI backend, service/repository, CLI
frontend/src/	React frontend
evaluation/	benchmark adapters, metrics, runners, reports
data/	
raw_sources/	
uploads/	
markdown_wiki/	
exports/	
backups/	
logs/	
docs/final-assets/	diagrams, screenshots, command logs

8.3 索引设计

项目使用多类 PostgreSQL 索引：

类别	用途	示例
B+ tree / B-link tree	workspace 过滤、排序、主键/外键查找	idx_memory_workspace_status
复合索引	租户隔离 + 状态/类型筛选	idx_memory_workspace_type_status
DESC 排序索引	时间线、审计、recall 最近记录	idx_audit_workspace_time
GIN FTS	tsvector @@ tsquery 全文检索	idx_memory_fts、idx_source_chunk_fts
GIN trigram	ILIKE '%keyword%' 模糊匹配	idx_memory_canonical_text_trgm
Partial index	active hot path / NULL 策略去重	idx_policy_global_unique
BRIN	append-only audit 时间窗分析	idx_audit_brin_time
Covering index	index-only scan	idx_memory_active_ranking
Embedding metadata index	provider/model 缓存定位	idx_memory_embedding_workspace_model

课堂上讲的 B+ tree 与 PostgreSQL 文档中的 B-tree 名称需要解释：PostgreSQL 实际实现是 Lehman-Yao B-link tree，是 B+ tree 的并发变种，叶子层保存 row pointer 并支持范围扫描。因此报告中可把 PostgreSQL 默认 btree 作为 B+ tree 变种说明。

8.4 EXPLAIN 证据

docs/explain-analyze.md 收集了 4 个实际 EXPLAIN ANALYZE 案例：

- 1. idx_memory_active_ranking 支撑 active memory 排序，出现 Index Only Scan 和 Heap Fetches: 0；
- 2. Recall 主查询使用 GIN tsvector + GIN trigram，并在强制索引路径下出现 BitmapOr；
- 3. audit_log 时间窗聚合展示 B-tree 竞争路径与 BRIN 路径；
- 4. Wiki provenance join 展示多跳来源追溯。

这些案例用于证明索引不是“写在 SQL 文件里”，而是能通过 PostgreSQL planner 的真实执行计划验证。

8.5 视图设计

视图	作用
v_active_memory	查询 active 且仍在有效期内的 memory
v_memory_with_source	串联 memory、evidence、chunk、source，支撑 provenance
v_agent_visible_memory	展开每个 Agent 可见的 active memory
v_project_timeline	串联 timeline、memory 和 source
v_conflict_memory	展开 conflict 两端 memory
v_wiki_page_sources	追溯 WikiPage 到 source chunk
v_memory_statistics	按 workspace、类型、状态、访问级别统计
v_memory_recall_statistics	从 recall log 反查 recall_count 和 last_recalled_at

8.6 触发器设计

触发器	用途
trg_memory_before_update	同一事务内递增 revision、维护状态变化前置逻辑
trg_memory_after_insert	memory 创建后写初始 revision 和 audit
trg_memory_after_update	memory 修改后写 revision、audit，并标记 Wiki rebuild
trg_memory_soft_delete	DELETE memory 转换为 archived
trg_wiki_revision_after_insert	Wiki revision 插入后同步 current revision
trg_conflict_after_insert / trg_conflict_after_update	open conflict 自动标记 memory 为 conflicted，解决后恢复

这些触发器让 revision、audit、soft delete 和 conflict lifecycle 不依赖应用层自觉执行。

9. 系统总体架构

9.1 总体架构



设计重点是 DB-first: 所有长期记忆、证据、权限、版本、审计、召回日志和 Wiki 投影都先进入 PostgreSQL。前端、CLI、Agent、Graph Explorer 和 evaluation runner 是围绕同一事实源的不同入口。

9.2 后端模块

后端采用 FastAPI router + service/repository 分层：

层	主要文件	作用
API layer	backend/app/api/*.py	定义 HTTP endpoints 和 Pydantic contract
Service layer	backend/app/services/*.py	封装 source、memory、recall、governance、graph、embedding、QA 等业务规则
Core	backend/app/core/*.py	配置、数据库连接
CLI	backend/app/cli/	mb / memorybase command line
Tests	backend/tests/	API、service、evaluation、PostgreSQL integration 测试

9.3 前端页面

前端按 workflow 分组：

分组	页面
Dashboard	Dashboard.jsx
Sources	Source list/detail
Memories	Memory list/detail/create/edit
Recall	Recall / Context Pack / QA
Wiki	Wiki export
Governance	Policies、Audit、Conflicts、ForgetRequests、Timeline
Runtime	Sessions、Messages、HybridSearch
Graph	GraphExplorer、GraphSvg

9.4 CLI 与 Agent Runtime

pyproject.toml 暴露 memorybase 和 mb 命令。CLI 覆盖 configure、health、context、recall、search、observe、remember、sessions 和 eval。Agent 可以通过 search/recall 获取上下文，通过 observe/remember 写入消息和 memory；Agent 写回 memory 时即使没有显式 evidence，后端也会创建 inline_agent_note source chunk，保证 provenance 不断裂。

10. API 与模块 IPO

10.1 API 摘要

模块	端点示例	作用
Health	GET /api/health	服务和数据库状态
Source	POST /api/sources、GET /api/sources/{id}	source 导入、列表、详情
Memory	POST /api/memories、PATCH /api/memories/{id}、POST /api/memories/batch	memory CRUD、批量创建、supersession
Memory Extraction	POST /api/memory-extraction/from-chunks、/api/memory-candidates/{memory_id}/approve	rule-based / optional LLM candidate extraction 和审批
Recall	POST /api/recall、POST /api/recall/context-pack	keyword/vector/hybrid recall 和 context pack
Search	POST /api/search	lexical search
Wiki	POST /api/wiki/export	Markdown Wiki 投影
Governance	/api/audit、/api/policies、/api/conflicts、/api/forget-requests、/api/timeline	审计、权限、冲突、遗忘、时间线
Runtime	/api/sessions、/api/observe	Agent Runtime 会话与消息
Graph	/api/graph/*	PostgreSQL graph preview、Neo4j sync/load
Embeddings / QA	/api/embeddings/*、/api/qa/answer	可选 embedding 和 LLM answer


完整 API 设计见 docs/08-api-design.md。

10.2 模块 IPO 表

模块	Input	Process	Output
Source / Ingest	Markdown / txt / meeting text	校验、checksum、切 chunk、生成 search text	SourceDocument、SourceChunk
Memory / Evidence	chunk、表单、Agent 写回	创建 memory、绑定 evidence、必要时创建 inline evidence	MemoryItem、MemoryEvidence
Memory Extraction	workspace_id、chunk_ids、max_candidates、method、llm options	rule-based 或 optional LLM 抽取、分类、创建 candidate、记录 run audit	Candidate Memory
Recall	query、filters、agent_id、retrieval_mode	visibility filter、FTS/trigram、可选 embedding、fallback metadata	RecallResponse、Context Pack
Policy / Visibility	principal、resource、scope、effect	allow/deny 策略和 per-agent visibility view	AccessPolicy、visible memory
Wiki	memory / scene / workspace	渲染 Markdown frontmatter/body、写 revision	WikiPage、Markdown 文件
Conflict Governance	两条 memory	创建/更新 conflict，trigger 标记状态	ConflictRecord、AuditLog
Forget Governance	target、reason、reviewer	审批、软遗忘、验证、审计	ForgetRequest、target status
Graph Explorer	workspace_id、agent_id	PostgreSQL 构图、可选 Neo4j sync	Graph nodes/edges
Evaluation	dataset adapter、runner config	加载 benchmark case、运行 metrics、生成 report	Evaluation report

11. 系统实现

11.1 Source 到 Wiki 端到端实现




端到端链路包括：

- 1. POST /api/sources 导入原始文档；

2. service 计算 checksum 并切分 source chunk;
3. 手动创建 memory 或从 chunk 通过 rule-based / optional LLM 生成 candidate;
4. approve candidate 后进入 active lifecycle;
5. `memory_evidence` 保证 memory 可追溯;
6. trigger 写 revision / audit;
7. Wiki service 将 memory/scene 投影为 Markdown。

11.2 Recall 与 Context Pack



Recall 支持 keyword、vector、hybrid 三种模式。未配置 embedding 或没有 embedding records 时，hybrid 会透明降级到 keyword，并在 `retrieval_info` 中返回 requested mode、effective mode、candidate count 和 fallback reason。前端 Recall 页面默认使用 keyword 以保证 demo 稳定，后端 API 默认保留 hybrid 合约。

11.3 当前已实现的 AI 功能与边界


当前项目已经实现的 AI 相关能力，主要集中在“可选增强层”而不是“事实源主链路”：

1. Memory Extraction 支持两条候选抽取路径：默认 `rule_based`，以及 `method='llm'` 的 optional OpenAI-compatible analysis path。
2. 两条路径都会先写入 `memory_item(status='candidate')`，并绑定 `memory_evidence`、记录 `memory_extraction.run.start/complete` 审计事件；新候选不会直接进入默认 recall，仍需人工 approve / reject。
3. Recall 支持 keyword / vector / hybrid 三种模式；embedding 默认是本地 hashing cache，未配置外部 embedding provider 或没有匹配 embedding records 时，会透明 fallback 到 keyword。
4. QA 支持基于 recall context 的 optional LLM answer path；只有配置兼容 provider 后才启用，不影响离线 demo 主路径。
5. 前端 Sources -> Source Detail 已支持勾选 Use LLM 触发候选抽取；CLI 也提供 `mb extract --method llm` 入口。

这部分能力的设计边界也需要明确说明：


- 默认演示链路仍是本地可运行的 `rule_based extraction + keyword recall`，不依赖外部 API key。
- LLM 当前只参与“候选记忆草拟”和“可选 QA 回答”，不直接写入 `active facts`，也不绕过 `evidence / approval / audit`。
- 当前尚未实现更完整的 `analysis_run`、`analysis_memory_draft`、`analysis_draft_evidence` 草稿表 workflow；optional LLM extraction 是在现有 candidate lifecycle 上的增强，而不是替代现有 schema。

11.4 Governance Lifecycle



治理链路覆盖 memory update/delete、conflict create/resolve、forget request approve/verify、wiki revision 等事件。数据库触发器负责 revision、audit、soft delete 和 conflict status，同步到前端 governance 页面和 SQL demo 查询。

11.5 Memory 状态机



memory_item.status 当前支持 7 个状态：

```
candidate -> active / rejected
active -> archived / forgotten / superseded / conflicted
conflicted -> active / superseded / forgotten
archived -> forgotten
```

状态转换由 service 校验，数据库 trigger 负责记录 revision 和 audit。

12. 系统演示

12.1 演示准备

```
npm run db:setup
```

该命令会重建 public schema，加载 database/00_init.sql 到 database/07_seed.sql，执行 search backfill，加载 database/10_governance_demo_fixture.sql，并运行 database/08_demo_queries.sql。演示数据包含 source、memory、evidence、revision、audit、wiki、policy、conflict、forget request 等对象。

12.2 演示路径

- 1. 打开 Dashboard，展示 workspace 统计。
- 2. 进入 Sources，展示 seeded discussion documents。
- 3. 打开 Source detail，查看 chunk 行号并选择待抽取的 chunk。
- 4. 先运行默认 rule-based candidate extraction，再勾选 Use LLM 运行 optional LLM extraction，对比候选类型与置信度。
- 5. 进入 Memories，展示 memory type/status/importance。
- 6. 打开 Memory detail，展示 evidence 和 revision。
- 7. 在 Recall 搜索“为什么放弃校园食堂系统”。
- 8. 生成 Context Pack，展示 Agent-ready Markdown。
- 9. 如配置 LLM provider，点击 Ask，展示 optional QA answer。
- 0. 展示 Governance：audit、policies、conflicts、forget requests、timeline。
 - 1. 展示 Graph Explorer。
 - 2. 展示 SQL 查询结果和 EXPLAIN 证据。

12.3 具体演示示例

12.3.1 Source 详情、chunk 行号与候选抽取入口




图 12-1 Source detail 页面同时展示原始文本、chunk 行号，以及 Use LLM 候选抽取入口。

这张图说明 source 导入后并不是黑盒切分；用户可以明确看到文档内容、chunk 的边界与行号，并在同一页面选择哪些 chunk 进入 candidate extraction 流程。

12.3.2 Memory detail 的 evidence 与 revision




图 12-2 Memory detail 页面展示 memory 内容、evidence、revision、entity 和 scene。

这张图对应本系统 “provenance-first” 的核心设计：每条 memory 都能向下追溯到 source chunk，并能向后查看 revision 历史，而不是只保留一段不可解释的摘要文本。

12.3.3 Recall 结果与 retrieval metadata




图 12-3 Recall 页面返回与 “为什么放弃校园食堂系统” 相关的记忆结果，并显示 requested / effective retrieval mode。

该图展示了数据库事实源上的 recall 能力：不仅返回答案相关 memory，还把 retrieval_info 暴露给前端，说明实际使用了什么检索模式，以及是否发生了 fallback。

12.3.4 Context Pack 投影




图 12-4 Recall 结果可进一步投影为 Agent-ready Markdown Context Pack。

这张图说明 Recall 并不止于“查到结果”，而是能够把 memory、evidence、citation 和 retrieval metadata 组织成可供 Agent 继续使用的上下文包。

12.3.5 Optional LLM candidate extraction 对比

为验证 optional LLM extraction 的价值，我们对同一组三条 chunk 分别运行默认 rule-based 路径和 Qwen-compatible analysis path。




图 12-5 默认 rule-based candidate extraction 结果。




图 12-6 启用 Qwen-compatible optional LLM extraction 后的结果。

Chunk 内容 (缩写)	Rule-based 结果	Qwen LLM 结果
abandoned cafeteria	decision , confidence 0.65 , importance 4	decision , confidence 0.90 , importance 4
PostgreSQL source of truth	task , confidence 0.65 , importance 3	decision , confidence 0.90 , importance 5
private budget notes hidden	constraint , confidence 0.65 , importance 4	policy , confidence 0.90 , importance 4

这组对比很好地验证了 rule-based 路径的局限与 optional LLM 路径的优势。第一句两条路径都能识别为 decision，但 LLM 给出了更高的 confidence；第二句没有再被 should 误判成 task，而是更准确地识别为架构 / 数据库方向的 decision；第三句也从较宽泛的 constraint 收敛为更贴近权限治理语义的 policy。同时，两条路径都只把结果写入 status='candidate'，仍然需要人工 approve / reject，因此语义增强并没有破坏 provenance、audit 和 human-in-the-loop 的主链路。

12.3.6 Optional QA answer




图 12-7 配置 optional LLM provider 后，Recall 页面可直接生成带引用的回答。

这里展示的是基于 recall context 的 optional QA path。它不是演示主链路所必需的能力，但在配置兼容 provider 后，可以把已召回的 memory 组织成最终回答，并显示使用的模型和 supporting memories 数量。

12.3.7 Governance 冲突治理




图 12-8 Governance 页面展示 open / resolved conflict 的生命周期。

这张图说明 conflict governance 并不是文档中的概念，而是落在了可浏览、可 resolve / ignore / reopen 的具体 workflows 中，并与后端 trigger / audit 逻辑对应。

12.3.8 Graph Explorer




图 12-9 Graph Explorer 基于 PostgreSQL 事实源渲染 workspace knowledge graph。

该图一方面展示了 source、chunk、entity、scene、wiki 等节点的可视化关系，另一方面也清楚显示 Neo4j 是 optional 的；即使 Neo4j disabled，PostgreSQL preview 仍可独立完成图谱展示。

完整截图索引见 docs/final-assets/screenshots/README.md。

13. 测试与评估

13.1 自动化测试

当前测试覆盖：

类别	测试文件示例	覆盖目标
API / service	test_sources.py、test_memories.py、test_recall_query.py	source、memory、recall
Governance	test_governance.py、test_graph_service.py	policy、audit、conflict、forget、graph visibility
CLI / Agent Runtime	test_cli_context.py、test_cli_recall.py、test_cli_sessions.py、test_cli_writeback.py	context、recall、observe、remember
Evaluation	test_evaluation_*	adapters、metrics、judging、checkpoint、report
PostgreSQL integration	test_postgres_integration.py	schema、seed、trigger、batch create、supersession
Frontend	npm run lint、npm run build	React lint 和 production build

最终提交前推荐命令：

```
uv run ruff check backend/app backend/tests evaluation
uv run --with pytest python -m pytest backend/tests -q
cd frontend && npm run lint && npm run build
git diff --check
```


最近一次合并后的验证记录包括：

- `uv run ruff check backend/app backend/tests evaluation` 通过；
- `.venv/bin/python -m pytest backend/tests -q` : 197 passed, 1 skipped；
- PostgreSQL batch/supersession focused integration tests: 2 passed, 41 deselected。

13.2 SQL 演示测试

`database/08_demo_queries.sql` 提供课程演示 SQL，覆盖 provenance、agent visibility、audit/revision、conflict、forget、statistics、wiki sources 等路径。`docs/final-assets/screenshots/logs/` 保存完整命令输出，PNG/SVG 是从完整日志渲染得到，避免终端截图截断。

13.3 Evaluation 结果与解释

Evaluation framework 覆盖 datasets、adapters、metrics、runners 和 reports。当前已完成一次 LongMemEval oracle 500-case live `db_qa` 运行：

Metric	Result
Cases	500
API errors	0
Deterministic pass	176 / 500 (35.2%)
Semantic judge pass	292 / 500 (58.4%)
Semantic judge fail	208 / 500 (41.6%)

分类结果显示系统在 `abstention`、`temporal_update`、`single_fact` 上表现较好，在 `multi_session reasoning` 和 `preference_following` 上较弱。这一结果应作为工程验证和限制分析，而不是榜单宣传。MemoryBase 的主价值是：用数据库事实源、provenance、governance、agent visibility 和 audit 支撑长期记忆任务，并用 evaluation 暴露真实边界。

14. 创新点总结

14.1 DB-first AI substrate

MemoryBase 把 AI 长期记忆从模型或向量库的黑盒能力转化为 PostgreSQL 中可验证的关系模型。LLM、embedding、Graph 和 evaluation 都是围绕数据库事实源的增强层。

14.2 Provenance-first 证据链

`memory_evidence`、`v_memory_with_source`、`v_wiki_page_sources`、`recall_log.context_pack_json` 让系统能回答“这条记忆来自哪里”“这次 recall 用了哪些 memory”“Wiki 页面引用了哪些 source”。

14.3 Governance-by-default 生命周期

`revision`、`audit`、`conflict`、`forget`、`policy` 被设计为核心表和触发器逻辑，不是 UI 装饰。状态变更、软删除和冲突 lifecycle 都可被 SQL 验证。

14.4 Agent-aware visibility

Agent 不是普通用户别名，而是独立 principal。系统通过 `access_policy` 和 `v_agent_visible_memory` 把权限过滤放入数据库查询路径，而不是依赖 prompt 中的自律。

14.5 Transparent hybrid retrieval

系统支持 keyword/vector/hybrid recall，但不假装向量永远可用。无 embedding 时明确 fallback 到 keyword，并记录在 `retrieval_info` 和 `recall_log` 中。

14.6 AI-assisted candidate extraction

MemoryBase 先用 rule-based 路径交付了稳定的 candidate extraction，随后又增加了 optional LLM analysis path。两条路径都会把候选记忆写入 `memory_item(status='candidate')`，并绑定 evidence、记录 run-level audit。这样既避免了“LLM 直接写事实”的风险，也避免了“大量文档完全靠人工处理”的低效。

14.7 Graph as provenance visualization

Graph Explorer 用 PostgreSQL 构建 workspace graph，并可选同步 Neo4j。图层服务关系展示和 provenance 可视化，不替代 PostgreSQL 事实源。

14.8 Evaluation-backed validation

Evaluation framework 让系统不只做 UI demo，还能用 LoCoMo / LongMemEval / MemoryAgentBench 等基准检查长期记忆行为。当前低分项也帮助明确 future work。

15. 小组分工与个人完成情况

本节基于 docs/gap6-contribution-ledger.md 在 2026-06-14 的 Git commit 审计刷新。

成员	主要负责	交付成果
林纪帆 (hopecommon / jflin)	数据库 schema、治理与溯源模型、lexical search / context-pack formatter / CLI dogfood、Graph hardening、审查合并/集成补强、最终报告证据资产	SQL schema、views、triggers、indexes、seed/demo data; governance/provenance workflows; CLI recall/context/eval/sessions/observe/remember; Graph visibility/sync/audit hardening; ER/sequence diagrams; 截图、final report 和 final defense slides
杜卓轩 (dzx0902 / dzx)	P0 backend/tests、evaluation benchmark framework、LoCoMo / LongMemEval / MemoryAgentBench adapters、LongMemEval full-run evidence、embedding/hybrid recall、memory extraction、QA、CI/tooling	FastAPI 后端基础、测试体系、evaluation datasets/adapters/metrics/runners/reports、semantic judging、checkpoint/resume、embedding/cache/hybrid recall、batch memory write、supersession
李昭成 (huiyijian / lywzc0419 / lzc)	前端 API 集成、runtime/governance UI、多页面联调、Neo4j Graph Explorer 初版集成	Dashboard、sources、memories、recall、governance、wiki、runtime、graph 等页面联调; graph API/service/model、Neo4j demo SQL、依赖配置和 lint/import 修复
王星睿 (Cofstars)	source extraction workflow、chunking/test additions、source UI creation/detail flow、optional LLM-backed candidate extraction、相关 CLI/API/tests、final report 与 PPT	source extraction candidate workflow; chunking 逻辑与测试; SourceCreate.jsx / SourceDetail.jsx 抽取交互; backend/app/services/llm_analysis.py; mb extract CLI; memory extraction API/service/tests; final report 与 final defense slides

分工边界说明：recall/search/context pack 是协作模块。hopecommon 主要负责 lexical search、context-pack formatter 和 CLI/dogfood；dzx0902 主要负责 hybrid recall、embedding、QA 和 structured context metadata；Graph 初版由 lywzc0419 集成，后续 visibility/sync/audit hardening 由 hopecommon 完成；Cofstars 工作集中在 source extraction、optional LLM extraction、PPT 和报告。

16. 带注释源程序与附录

16.1 SQL 源程序

文件	内容
database/00_init.sql	PostgreSQL extension 初始化
database/01_schema_core.sql	用户、workspace、agent、member
database/02_schema_memory.sql	session、source、chunk、memory、evidence、embedding、entity、scene
database/03_schema_governance.sql	wiki、timeline、recall log、policy、forget、conflict、audit
database/04_indexes.sql	B+ tree、GIN、BRIN、covering、partial index
database/05_views.sql	provenance、visibility、statistics、conflict、wiki source views
database/06_triggers.sql	revision、audit、soft delete、conflict lifecycle
database/07_seed.sql	demo seed
database/08_demo_queries.sql	演示查询
database/09_graph_demo.sql	optional graph demo data
database/10_governance_demo_fixture.sql	governance fixture

16.2 高级语言源程序

目录 / 文件	内容
backend/app/main.py	FastAPI app 和 router 挂载
backend/app/api/	HTTP API
backend/app/services/	核心业务逻辑
backend/app/cli/	mb / memorybase CLI
frontend/src/	React 前端
evaluation/	benchmark adapters、metrics、runners、reports
backend/tests/	测试

详细源码清单和建议摘录见 docs/gap8-source-sql-appendix-map.md。

17. 总结与展望

MemoryBase 完成了一个工程上可运行、演示闭环清晰的组织级长期记忆系统。它把 AI memory 从“聊天产品里的黑盒功能”转化为 PostgreSQL 中可建模、可约束、可审计、可追溯、可被 Agent 调用的数据库应用。

已完成的核心价值：

- 完整的 source -> memory -> evidence -> revision -> audit -> wiki 链路；
- 关系模型、E-R、范式、物理设计和 SQL 源程序齐全；
- B+ tree、GIN、BRIN、covering index 等索引策略有 EXPLAIN 证据；
- governance、provenance、agent visibility 是 schema 级能力；
- 前端、后端、CLI、evaluation 和截图证据形成可演示系统。

当前边界：

- 自动抽取已支持 rule-based 和 optional LLM 两条路径，但还不是完整的 LLM analysis draft-table workflow；
- JSONB embedding cache 适合课程规模，不替代大规模 pgvector / ANN；
- LongMemEval 结果适合作为工程验证，不适合作为高分榜单 claim；
- memory-level visibility 已实现，source/wiki 的更细粒度策略仍可扩展；

- Graph Explorer 是 provenance 可视化，不是默认 GraphRAG 检索主路径。

未来的可能拓展方向：

1. 引入 pgvector / HNSW / IVFFlat 支撑大规模向量检索；
2. 引入 LLM-backed analysis_run / analysis_memory_draft / analysis_draft_evidence 草稿表；
3. 扩展 source/wiki resource policy，形成更完整的多租户治理；
4. 增强 temporal reasoning、multi-session reasoning 和 preference following；
5. 完善 LoCoMo / MemoryAgentBench 对照实验和独立 judge；
6. 扩展 Obsidian/Git 双向同步和多 Agent 自动协作。

参考资料

- Lewis et al., Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, 2020.
- Park et al., Generative Agents: Interactive Simulacra of Human Behavior, 2023.
- Zhong et al., MemoryBank: Enhancing Large Language Models with Long-Term Memory, 2023.
- Packer et al., MemGPT: Towards LLMs as Operating Systems, 2023.
- Maharana et al., LoCoMo / Evaluating Very Long-Term Conversational Memory of LLM Agents, 2024.
- Wu et al., LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory, 2024.
- Chhikara et al., Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory, 2025.
- Hu et al., MemoryAgentBench, 2025.
- Edge et al., From Local to Global: A Graph RAG Approach to Query-Focused Summarization, 2024.
- PostgreSQL Documentation, B-Tree, GIN, BRIN, Generated Columns, PL/pgSQL Triggers.
- Atlassian Rovo / Confluence AI documentation.
- OpenAI Help Center, Memory FAQ.
- Letta, LangChain, LlamaIndex, Notion, Obsidian documentation.